

Análisis de Riesgo

Regresión Logística Explicable aplicada al Dataset
FICO HELOC

En la era de la IA, la "caja negra" ya no es una opción para la banca europea.

Benedict
Bagoyo

Contexto económico y legal

 **Regulación Estricta:** Bajo normativas como Basilea III y la inminente *EU AI Act*, las decisiones de crédito deben ser transparentes.

 **El Límite del Machine Learning:** Algoritmos complejos (Redes Neuronales, Random Forests) logran gran precisión, pero no pueden explicar *por qué* se

 **La Solución Clásica:** La regresión logística ofrece un equilibrio perfecto entre rentabilidad (precisión predictiva) y auditabilidad (Odds Ratios).



Análisis Exploratoria





Dataset HELOC: n = 9871 -> 9682, variables iniciales = 24 (cuantitativas) => 4 variables

0	RiskPerformance	9871 non-null	object
1	ExternalRiskEstimate	9861 non-null	object
2	MSinceOldestTradeOpen	9632 non-null	object
3	MSinceMostRecentTradeOpen	9871 non-null	object
4	AverageMInFile	9871 non-null	object
5	NumSatisfactoryTrades	9871 non-null	object
6	NumTrades60Ever2DerogPubRec	9871 non-null	object
7	NumTrades90Ever2DerogPubRec	9871 non-null	object
8	PercentTradesNeverDelq	9871 non-null	object
9	MSinceMostRecentDelq	5031 non-null	object
10	MaxDelq2PublicRecLast12M	9871 non-null	object
11	MaxDelqEver	9871 non-null	object
12	NumTotalTrades	9871 non-null	object
13	NumTradesOpeninLast12M	9871 non-null	object
14	PercentInstallTrades	9871 non-null	object
15	MSinceMostRecentInqexcl7days	7540 non-null	object
16	NumInqLast6M	9871 non-null	object
17	NumInqLast6Mexcl7days	9871 non-null	object
18	NetFractionRevolvingBurden	9685 non-null	object
19	NetFractionInstallBurden	6452 non-null	object
20	NumRevolvingTradesWBalance	9715 non-null	object
21	NumInstallTradesWBalance	9010 non-null	object
22	NumBank2NatlTradesWHighUtilization	9288 non-null	object
23	PercentTradesWBalance	9853 non-null	object
24	Target	9871 non-null	int64

Estadísticos descriptivos:

	ExternalRiskEstimate	NetFractionRevolvingBurden	NumSatisfactoryTrades
count	9682.00	9682.00	9682.00
mean	72.15	34.86	21.43
std	9.88	28.90	11.18
min	33.00	0.00	0.00
25%	65.00	9.00	13.00
50%	72.00	29.00	20.00
75%	80.00	56.00	28.00
max	94.00	232.00	79.00

Análisis Exploratoria



Selección Estadística de Variables

No incluimos las variables independientes al azar. Filtramos el ruido mediante tests rigurosos antes de entrenar el modelo.

↔ Variables Cuantitativas

Utilizamos el **T-test de muestras**

independientes

Comparamos la media del *ExternalRiskEstimate* entre el grupo que paga y el que no. Si el p-valor es < 0.05 , confirmamos que la variable discrimina correctamente y la incluimos en el modelo.

▣ Variables Categóricas

Utilizamos pruebas de **Chi-cuadrado** ().

Evaluamos si la proporción de impagos depende de características cualitativas.




Adicionalmente, se podría analizar el *VIF* (*Factor de Inflación de la Varianza*) para evitar multicolinealidad.

Selección Estadística de Variables

Hypothesis Test Summary				
Null Hypothesis		Test	Sig. ^{a,b}	Decision
1	The distribution of ExternalRiskEstimate is the same across categories of Target.	Independent-Samples Mann-Whitney U Test	<.001	Reject the null hypothesis.
2	The distribution of NumSatisfactoryTrades is the same across categories of Target.	Independent-Samples Mann-Whitney U Test	<.001	Reject the null hypothesis.
3	The distribution of NetFractionRevolvingBurden is the same across categories of Target.	Independent-Samples Mann-Whitney U Test	<.001	Reject the null hypothesis.
a. The significance level is .050.				
b. Asymptotic significance is displayed.				

Selección Estadística de Variables

T-Test: Distribución de Variables por Clase (Buenos vs Malos)



Definición de Variables Clave

Dataset HELOC: n = 9671, variable de interés: 4, Tasa de default (Bad): 51.49%




Variable Dependiente (Y)

RiskPerformance -> Target

Transformada a binaria: 1 =

Bad (Impago) y 0 = Good

(Paga). Modelaremos la probabilidad de pertenecer a la clase 1.



Covariables

- ExternalRiskEstimate
Score crediticio consolidado externo. Hipótesis económica: a menor puntuación, mayor probabilidad de colapso financiero.
- NetFracRevolBurden
- NumSatisfactoryTrades



Comportamiento

NetFractionRevolvingBurden

Porcentaje de uso límite de las tarjetas. Un indicador crítico de asfixia de liquidez a corto plazo en el cliente.

Tratamiento de las variables cualitativas con categorías

Agrupamiento semántico

Evitar introducir variables categóricas con más de 4 o 5.

Variables dummy

- Definir la categoría de referencia
- Trabajar con variables binarias (0/1).

Train-test split para el modelo (70% - 30%)

Logit Regression Results

Dep. Variable:	Target	No. Observations:	6777
Model:	Logit	Df Residuals:	6773
Method:	MLE	Df Model:	3
Date:	Wed, 11 Mar 2026	Pseudo R-squ.:	0.1791
Time:	01:11:43	Log-Likelihood:	-3853.6
converged:	True	LL-Null:	-4694.5
Covariance Type:	nonrobust	LLR p-value:	0.000

→ Logistic Regression

Case Processing Summary

Unweighted Cases ^a		N	Percent
Selected Cases	Included in Analysis	6777	70.0
	Missing Cases	0	.0
	Total	6777	70.0
Unselected Cases		2905	30.0
Total		9682	100.0

a. If weight is in effect, see classification table for the total number of cases.

Ajuste por Máxima Verosimilitud (MLE). $y = \beta_0 + \beta_1 \times ERE + \beta_2 \times NFRL + \beta_2 \times NST$

$$Z_w = \frac{\beta_k}{SE(B_k)}$$

$0 \notin Interval$

Interpretación Económica: Odds Ratios: e^{β_k}


		Variables in the Equation					
		B	S.E.	Wald	df	Sig.	Exp(B)
Step 1 ^a	ExternalRiskEstimate	-.097	.004	636.977	1	<.001	.908
	NumSatisfactoryTrades	-.028	.003	118.383	1	<.001	.973
	NetFractionRevolvingBurden	.008	.001	40.759	1	<.001	1.008
	Constant	7.395	.316	546.244	1	<.001	1627.081
a. Variable(s) entered on step 1: ExternalRiskEstimate, NumSatisfactoryTrades, NetFractionRevolvingBurden.							

Narrativa: Por cada 1% adicional que el cliente consuma del límite de su tarjeta, las probabilidades (odds) de impagar **aumentan un 0.8%** (Por el contrario, un mejor Score reduce notablemente el riesgo (0.908)).

Calibración: Test de Hosmer-Lemeshow


¿Dice el modelo la verdad?

Hosmer and Lemeshow Test			
Step	Chi-square	df	Sig.
1	12.911	8	.115




Contingency Table for Hosmer and Lemeshow Test						
		Target = 0		Target = 1		Total
		Observed	Expected	Observed	Expected	
Step 1	1	588	573.358	90	104.642	678
	2	534	528.645	144	149.355	678
	3	464	479.280	214	198.720	678
	4	430	418.842	248	259.158	678
	5	345	355.024	333	322.976	678
	6	278	293.408	400	384.592	678
	7	244	238.831	434	439.169	678
	8	173	184.721	505	493.279	678
	9	135	135.213	543	542.787	678
	10	97	80.678	578	594.322	675

Bondad de Ajuste: Histograma, Matriz de Confusión, Curva ROC



Tasa de default (Bad): 51.49%

Equivalentes en SPSS



Bootstrapping: estabilidad de las métricas calculadas

RESULTADOS DEL BOOTSTRAP (Intervalos de Confianza al 95%):

	Coef.	IC_Inf(Coef)	IC_Sup(Coef)	Odds Ratio	IC_Inf(OR)	IC_Sup(OR)
const	7.3899	6.7435	8.0290	1619.6152	848.5606	3068.5655
ExternalRiskEstimate	-0.0969	-0.1049	-0.0890	0.9077	0.9004	0.9148
NetFractionRevolvingBurden	0.0079	0.0055	0.0102	1.0079	1.0055	1.0103
NumSatisfactoryTrades	-0.0273	-0.0326	-0.0222	0.9730	0.9679	0.9780

Variables in the Equation

		B	S.E.	Wald	df	Sig.	Exp(B)	95% C.I. for EXP(B)	
								Lower	Upper
Step 1 ^a	ExternalRiskEstimate	-.097	.004	636.977	1	<.001	.908	.901	.914
	NumSatisfactoryTrades	-.028	.003	118.383	1	<.001	.973	.968	.978
	NetFractionRevolvingBurden	.008	.001	40.759	1	<.001	1.008	1.005	1.010
	Constant	7.395	.316	546.244	1	<.001	1627.081		

a. Variable(s) entered on step 1: ExternalRiskEstimate, NumSatisfactoryTrades, NetFractionRevolvingBurden.

Story-Telling: Aplicación al Negocio



Ejemplo Simulado: Cliente Entrante

Perfil: Score= 85, Uso de Tarjeta=10, Cuentas al día=30.

$$Z = \beta_0 + \beta_1 \times ERE + \beta_2 \times NFRL + \beta_3 \times NST$$

Resultado: Probabilidad de Default(Impago) = 0.12 .

Conclusiones

Hemos desarrollado un modelo **rentable**, estadísticamente **robusto**, y totalmente **explicable**, cumpliendo las regulaciones bancarias europeas sin sacrificar poder predictivo.